

Procesamiento espacial-espectral entrega 4
Sensado remoto
Nicolás Alberto Molina Cerón

Problema 1

Utilizando el mapa de clasificación resultante en la actividad 3 para Pavía y para Indian Pines, se creó un filtro para mejorar la clasificación, éste consistió en asignarle al píxel del centro la etiqueta más común que se obtuvo aplicando ventanas de 3×3 , 5×5 y 9×9 píxeles.

Pavía

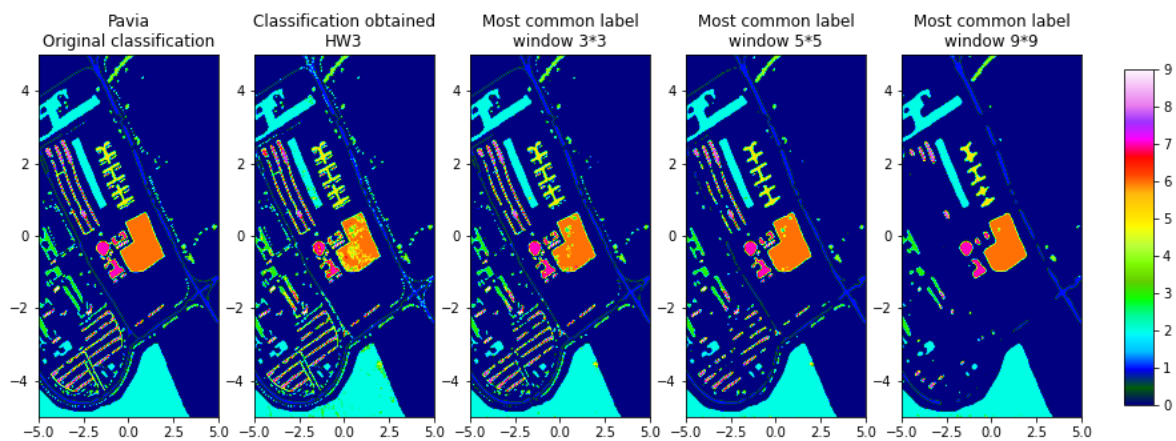


Figura 1. Clasificación original, obtenida en la hw3, con una ventana de 3×3 , con una ventana de 5×5 y una ventana de 9×9 .

Cómo se observa en la figura 1 cuanto se usa una ventana de votación con un tamaño 3×3 se ve un mejor resultado visualmente, con un tamaño 9×9 se empieza a perder información respecto a la forma de las etiquetas.

Para cada uno de las clasificaciones obtenidas se generó una matriz de confusión, estas se encuentran desde la figura 2 hasta la figura 5.



Figura 2. Matriz de confusión de la clasificación original vs la obtenida en la hw3.



Figura 3. Matriz de confusión de la clasificación original vs la obtenida por la ventana de 3*3..

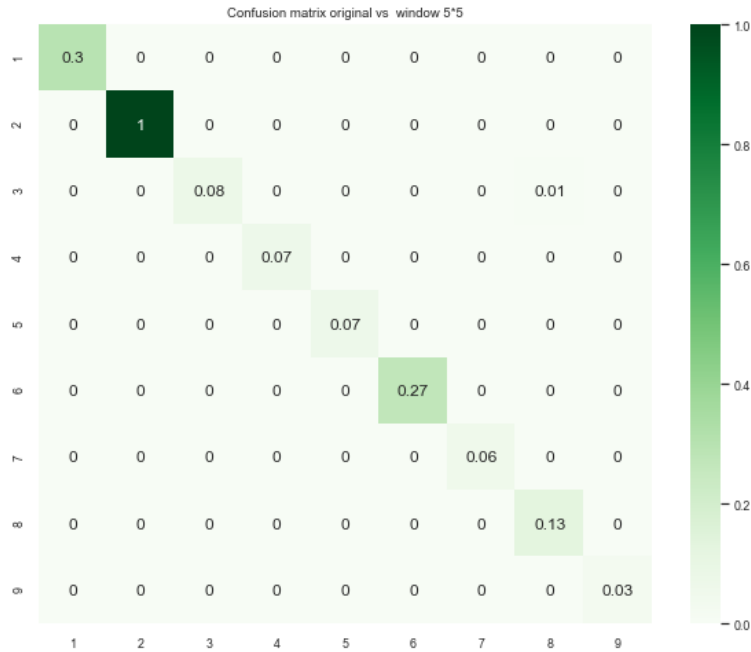


Figura 4. Matriz de confusión de la clasificación original vs la obtenida por la ventana de 5*5.

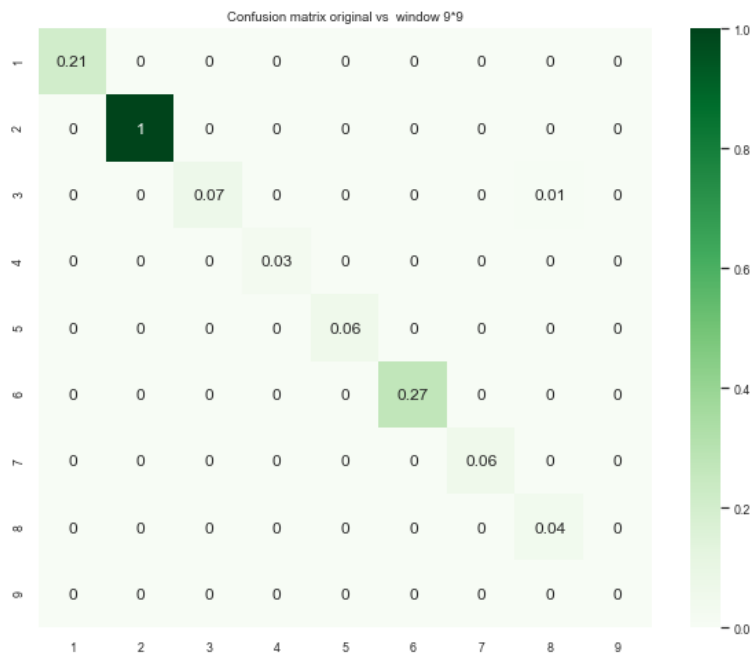


Figura 5. Matriz de confusión de la clasificación original vs la obtenida por la ventana de 9*9.

Cómo se puede observar en las matrices de confusión obtenidas, la que mejor desempeño tiene es la aplicada con una votación en una ventana de 3*3, ya que aunque disminuye en algunas etiquetas la correlación, esta disminución es muy corta comparada con las ventanas de 5*5 y 9*9

además disminuye los falsos positivos y negativos existentes en el caso obtenido en la HW3 ver figura 2.

Indian

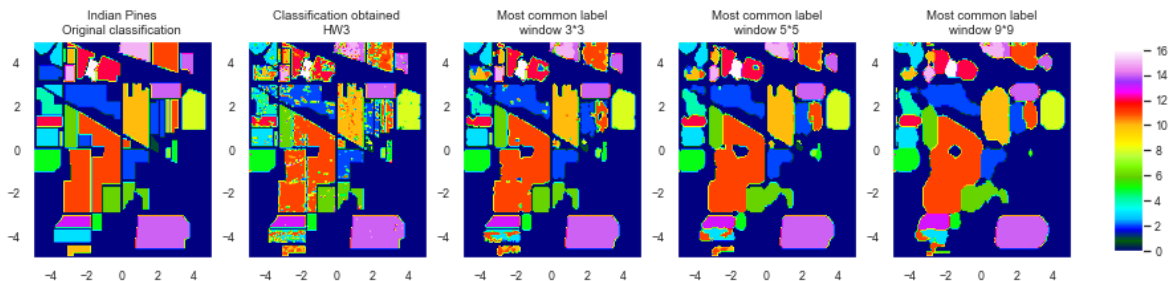


Figura 6. Clasificación original, obtenida en la hw3, con una ventana de 3*3, con una ventana de 5*5 y una ventana de 9*9.

Al igual que ocurrió con Pavía en el caso de Indian el que mejor desempeño visual tuvo es la clasificación aplicando una votación por mayoría en una ventana de tamaño 3*3.

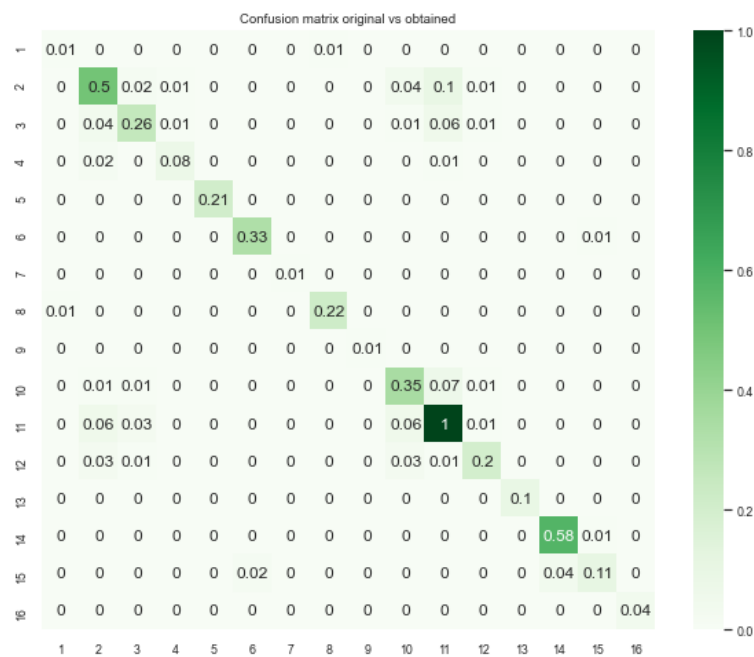


Figura 7. Matriz de confusión de la clasificación original vs la obtenida en la hw3.



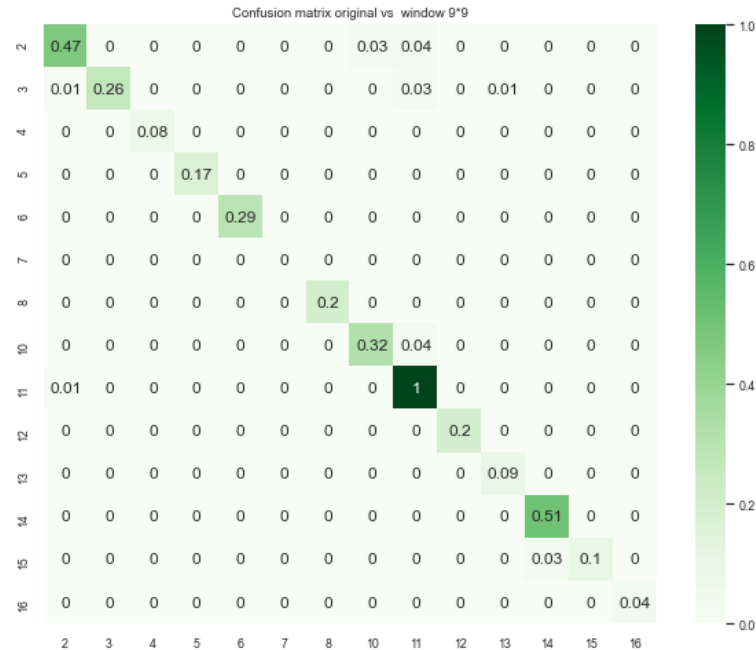


Figura 10. Matriz de confusi3n de la clasificaci3n original vs la obtenida por la ventana de 9*9.

Lamentablemente en las ventanas de votaci3n de 5*5 y 9*9 se llegan a perder etiquetas, por esta raz3n la que mejor resultados tiene es la ventana de 3*3, ver figuras desde la 7 a la 10.

Para el caso de la votaci3n de ventana de 5*5 se pierde la etiqueta 9 ver figura 9, mientras que para la ventana 9*9 se pierden las etiquetas 1 y 9 ver figura 10.

Problema 2

Se implement3 una segmentaci3n por color a 1 de las componentes principales tanto para Pavia, como para Indian. Se seleccion3 la primera componente con mayor varianza en donde para el caso de Pavia fue de: 0.58 y de Indian de: 0.68.

Pavia




Figura 11. Primer componente principal con varianza de 0.58.




Figura 12. Etiquetas generadas por la segmentación de color.

Debido a que la segmentación por color no genera etiquetas muy bien definidas desde la etiqueta 7 hasta la 9, se optó por utilizar las formas de la clasificación original.




Figura 13. Etiquetas generadas por el mapa de clasificación original.

Indian




Figura 14. Primer componente principal con varianza de 0.68.




Figura 15. Etiquetas generadas por la segmentación de color.

Al igual que ocurrió con Pavia se optó por generar la segmentación en base a la clasificación original ver figura 16 ya que una segmentación por color no genera buenas etiquetas para el caso 15 y 16, ver figura 15.




Figura 16. Etiquetas generadas por el mapa de clasificación original.

Problema 3

Para este problema se desarrolló un algoritmo que asignaba la etiqueta con mayor votación dada en la segmentación realizada en el problema 2, Para la asignación de Pavia ver figura 13 y 16 para Indian.

Pavia



Figura 17. Matriz de confusión entre clasificación original y la asignada por mayor votación.

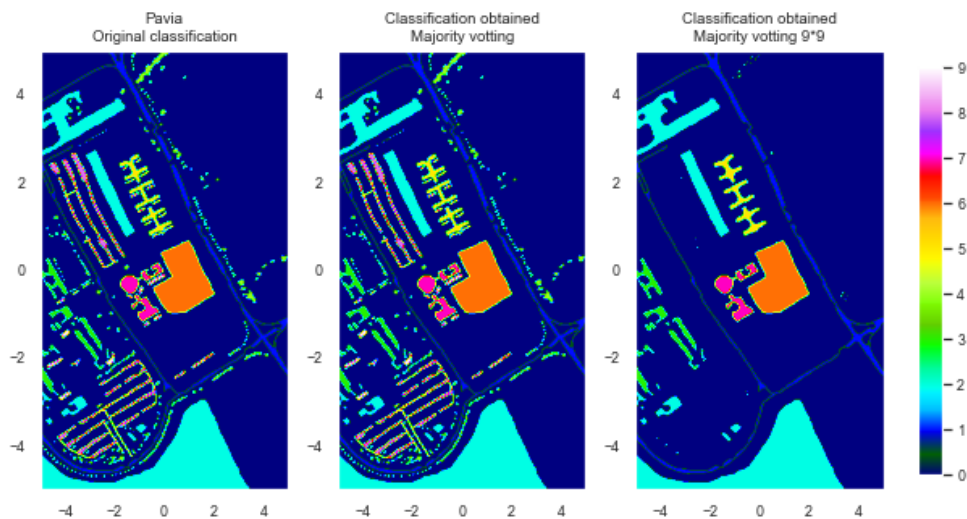


Figura 18. Clasificación original, obtenida por mayor votación según hw3 problema 3 y obtenida por mayor votación según el resultado de clasificación de una ventana 9*9.

Aplicando una votación por mayoría con base en la forma de la clasificación original se puede observar en la figura 17 que se obtuvo un muy buen resultado en la matriz de correlación, además

para efectos visuales se graficó el mapa de clasificación obtenido aplicando la mayoría de voto según la clasificación obtenida en la hw3 y la resultante al aplicarle una votación por ventana de 9*9 y después por la segmentación de la clasificación original.

Indian

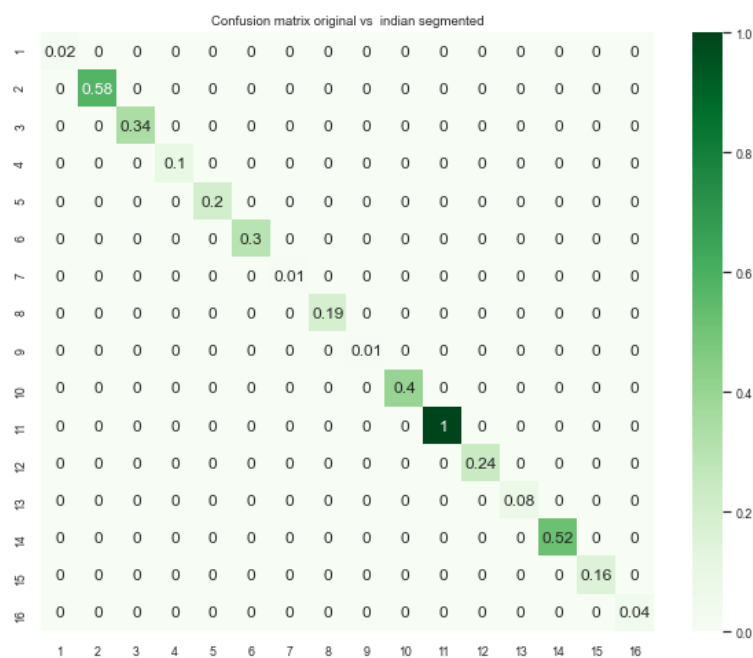


Figura 19. Matriz de confusión entre clasificación original y la asignada por mayor votación.

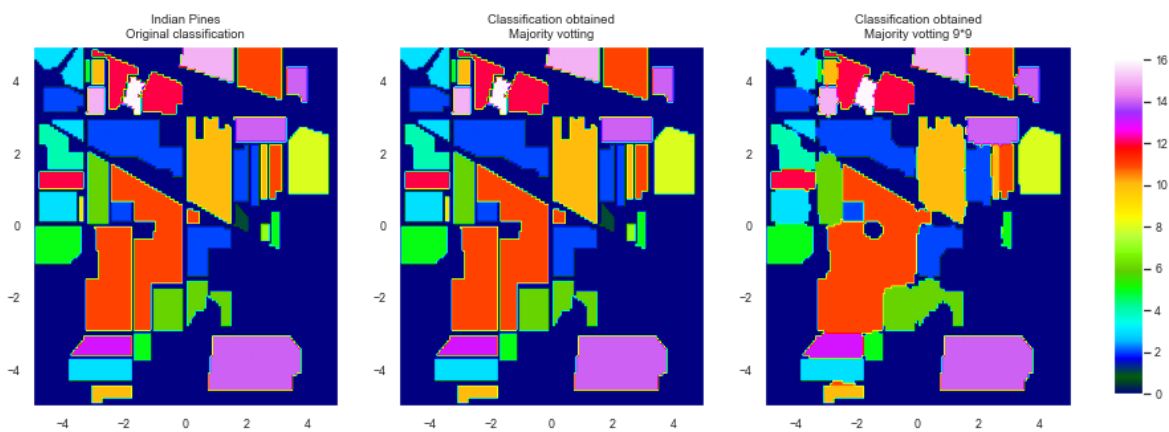


Figura 20. Clasificación original, obtenida por mayor votación según hw3 problema 3 y obtenida por mayor votación según el resultado de clasificación de una ventana 9*9.

Al igual que con los resultados obtenidos en Pavía, se puede observar que la clasificación obtenida después de asignarle la votación por mayoría de etiqueta al resultado de la hw3 existe una mejora

considerablemente. Ver figura 20, además en las figuras 19 y 7 se pueden comparar los resultados después de que se aplica la votación por mayoría donde en la figura 19 no hay falsos negativos.

Conclusiones

En el presente taller se llevó a cabo la visualización de clasificación de datos espectrales de Pavía e Indian Pines obtenidos en la Hw3 y la clasificación obtenida utilizando técnicas de votación por ventanas de 3*3, 5*5, 9*9 y de cierta forma en particular.

En ambos casos se evidenció un buen desempeño para la votación en las ventanas de votación de 3*3, mientras que en la votación de 9*9 los resultados obtenidos no son tan buenos, ya que en algunos casos se eliminaban etiquetas.

En el caso de la segmentación por color se decidió tomar la segmentación por la clasificación original donde ambos resultados fueron muy buenos, para todos los casos se obtuvieron sus matrices de confusión.

Referencias

Para el procesamiento, carga y visualización se utilizaron las siguientes librerías:

Sklearn: <https://scikit-learn.org/stable/>

matplotlib: <https://matplotlib.org/>

pathlib: <https://docs.python.org/3/>

osgeo: <https://gdal.org/python/>

numpy: <https://numpy.org/>

cv2: <https://opencv.org/>

Datos hiperespectrales tomados de <https://earthexplorer.usgs.gov/>